

動画像から抽出した位置関係による 烏骨鶏家族における関係性分析に向けた社会行動検出

岩本 純¹ 高野 耀希¹ 瀬口 瑛子² 新村 毅² 藤波 香織^{1,3}

概要：動物の社会行動の定量化は、集団形成や養育形態など家族関係の理解に重要であるが、多個体の長時間観察は人的コストが高く、成長に伴う外見変化や個体差により自動化が困難である。そこで本研究では、ヒトに近い養育形態を有することが示唆されている烏骨鶏の家族を対象とし、動画像から抽出した位置関係に基づく社会行動（approach, avoid, follow）検出手法を提案する。多様な家族への適用を見据え、未知のペアに対する汎化性能の実現も目指す。位置情報の抽出では Segment Anything Model 2（SAM2）による疑似マスク精緻化を伴う段階的自己学習を導入し、初日分のアノテーションのみで成長過程を含む長期間のトラッキングを実現した。さらに、深層学習モデルと隠れマルコフモデルを組み合わせた区間検出手法によって、社会行動の検出を実現した。一方、1 ペア抜き交差検証とクラス条件付き Maximum Mean Discrepancy（MMD）によって、特に母鶏に関わるペアで他のペア間より大きなドメインシフトが存在し、個体の重心間距離がその主要因であることが示唆された。

1. はじめに

動物行動の理解は、生態学や心理学にとどまらず、集団形成や相互作用といった社会現象の理解においても重要である。特に、複数個体間の関係性に基づく社会行動は、人間社会における家族関係や協調行動と共通する側面を有しており、動物モデルによる定量的解析が注目されている [1][2]。また、ヒトは生態学的に父母で養育を行い、非血縁者も養育に関与するが、これらの生態学的要件を満たす動物種は少ない [2][3]。そこで、本研究では鶏の一種である烏骨鶏に着目した。予備的な観察から、烏骨鶏はこれらの生態学的要件を満たすことが示唆されているが、実際に烏骨鶏の家族関係を明らかにした研究はほとんど存在しない。そのため、烏骨鶏の養育期間における社会行動を定量化し、その家族関係を理解することで、ヒトの養育形態に近い新たな家族モデルの提示が期待される。

しかし、多個体を対象とした長時間の観察による定量化は人的コストが高く、観察者の主観に依存するという問題がある [4][5]。また、加速度センサや識別タグを個体に装着する手法も提案されているが、個体への負荷や装着コストの問題から、集団飼育環境や小型動物への運用には制約が大きい [6][7]。これらの課題に対し、動画像解析を用いた非接触型の行動解析手法が注目されている。近年の画像

解析技術の発展により、単一個体の動きや姿勢を高精度に捉えることが可能となっている [8][9]。一方で、社会行動は複数個体間の距離や相対的な位置関係、およびその時間的な変化などに基づいて特徴づけられるため、各個体の行動ラベルの分類よりも、複数個体間の位置関係に着目した解析が有効であると考えられる。しかしながら、社会行動の検出には、行動境界が曖昧であることや、複数個体の相互関係に依存することなど、単一個体の行動検出とは異なる困難さが存在する [10][11]。

既存の研究 [12][13] は主に成熟した個体同士あるいは特定の短期間の社会行動に焦点を当てており、成長過程を含む長期間にわたる社会行動に焦点を当てた研究は、我々の知る限り存在しない。また、社会行動は動物種ごとの公開データセットが限られており、既存の社会行動ラベルやモデルを転用することが困難である [14]。

本研究では動画像解析によって抽出される位置関係を用いて、養育期間における家族間の長期的な関係性分析に向けた社会行動検出手法の構築を目的とする。なお、烏骨鶏の家族間で頻発し重要な社会行動として、他の個体へ近づく行動（approach）、他の個体から離反する行動（avoid）、他の個体を追従する行動（follow）の3つに着目する。

以下、2 章にて本研究と関連する研究について紹介し、3 章では、社会行動検出のためのデータ収集実験について述べる。4 章では各個体の位置情報の抽出手法と社会行動検出のためのモデル構築について述べ、5 章で構築した手法

¹ 東京農工大学 大学院 先進学際科学府 先進学際科学専攻

² 東京農工大学 農学部 生物生産学科

³ 東京農工大学 大学院 工学研究院 先端情報科学部門

の評価を行う。6章では評価結果に基づく考察を述べ、7章では本研究におけるまとめと今後の展望を述べる。

2. 関連研究

2.1 個体のトラッキング手法

2.1.1 姿勢推定による手法

動画画像から動物の社会行動を検出するにあたり、動画画像内において各個体の位置を正確にトラッキングすることは重要であり、動物の位置トラッキングに関する研究が多くなされている。中でも DeepLabCut[8] や SLEAP[9] といった姿勢推定モデルは、高精度なキーポイント検出を可能にし、社会行動分析において高いパフォーマンスを示すようになった [15]。一方、キーポイントのアノテーションはコストが高くドメイン知識が必要であり、異種に対する転用が困難であるという課題がある [5][16]。

2.1.2 インスタンスセグメンテーションによる手法

姿勢推定以外の手法として、物体の輪郭とその内部をマスク化して検出するインスタンスセグメンテーションが挙げられる。代表的なモデルとして YOLOv8[17] や Mask R-CNN[18] などが提案されている。マスク化によるトラッキングは姿勢推定によるトラッキングと比較して、異種に対する転用が容易でありアノテーション時のドメイン知識も不要であるという利点がある。しかしながら、個体の輪郭点をアノテーションする必要がある、姿勢推定と同様にアノテーションコストが大きいという課題がある [19]。

そこで、大規模な事前学習によって追加の学習無しで、動画画像上の任意の物体をマスク化可能な SAM2 (Segment Anything Model 2) [20] が提案された。SAM2 は対象の物体に対するクリック入力またはバウンディングボックス入力に基づいてマスク化を行うモデルである。SAM2 を動物の個体検出に転用した研究として、Mele ら [21] はショウジョウバエや幼生ゼブラフィッシュなどの小動物を半自動的に追跡するツールを作成した。ツールの追跡精度を検証した結果、移動距離の測定において手動アノテーションとの相関で $R^2 = 0.94$ を示し、アノテーションなしで高精度にトラッキング可能であることが示唆された。

一方で、SAM2 はエラー蓄積による精度低下や情報保持によるメモリ不足によって長時間の動画に対して直接適用することが困難である。そこで、SAM2 をアノテーションツールとして用いることで、小さいアノテーションコストでインスタンスセグメンテーションモデルの学習が可能となり、長時間のトラッキングも可能となると考える。

2.1.3 外見変化に適応した手法

成長過程を含む長期間のトラッキングにおいては、子の成長に伴う外見の変化に伴って精度が低下することが知られており [22]、外見変化に適応した手法が必要とされる。Kumar ら [23] は、段階的自己学習によって、外見変

化に適応する手法を提案した。提案手法では、初期ドメインにおける正解ラベルを用いてモデルを訓練し、次のドメインのデータに対して予測を行うことで疑似ラベルを生成し、次のドメインのデータに対してモデルを再訓練する。このプロセスを繰り返すことで、段階的にドメイン適応が可能となる。評価の結果、提案手法は回転 MNIST や Portraits[24] のような外見が段階的に変化するようなデータセットに対して、ソースドメインで学習したモデルを直接適用する場合と比較して高い精度を示した。

また、Wang ら [25] は Kumar らの段階的自己学習を発展させ、中間ドメインの数や配置が目的ドメインの精度に与える影響を実験的に検証した。回転 MNIST や Portraits データセットにおいて、中間ドメインの数 T を変化させたときの分類精度を調査した。その結果、Portraits データセットでは、ソースドメインのみで学習した場合の分類誤差が約 0.36 であるのに対し、適切な数の中間ドメインを用いた段階的自己学習では約 0.21 まで誤差が低下することが確認された。さらに、同じ中間ドメイン数でも、隣接ドメイン間の距離が小さくなるように密に配置された経路を選ぶことで精度が改善することも示された。

これらの結果は、外見が連続的に変化する系列に対する段階的自己学習の有効性を示しており、本研究のような成長過程を含む長期間のトラッキングを行う場合に対しても有効であることが期待される。

2.2 社会行動の検出

2.2.1 社会行動の重要性と課題

動物行動学において、接近、回避、グルーミングや攻撃などといった社会行動は、優劣関係の定量化や養育行動の評価に広く用いられている [26][27]。従来、これらの社会行動の記録は訓練された観察者による目視観察に依存してきたが、サンプリング手法や観察者の主観によってバイアスが生じるといった問題がある [11][28][29]。また、多個体の同時観察や長時間にわたる連続記録が困難であることも指摘されている [12]。

動画画像解析による社会行動の自動検出は、これらの制約を克服し、目視観察では困難であった長時間・多個体にわたる網羅的な社会行動の定量化を実現する [30]。これにより、行動頻度の時間変化やペア間の比較、発達段階に応じた関係性変化といった、質的に異なる分析が可能となる。

2.2.2 位置関係を用いた社会行動の検出

Burgos-Artizzu ら [13] は、動画画像からマウスの 2 個体間において 12 種類の行動とその他を分類する手法を提案した。提案手法では、各個体の重心位置を取得し、そこから時空間特微量と軌跡特微量の 2 種類の局所特微量を抽出し、AdaBoost 分類器に入力する。評価の結果、13 カテゴリで平均認識率 0.61 を達成し、専門家間の一致率である

0.70 に近い性能を示した。

また、Segalin ら [12] は重心情報に加えてキーポイント情報も用いてマウスの 2 個体間における社会行動を検出するパイプラインである Mouse Action Recognition System (MARS) を構築した。MARS では、各個体のキーポイントから位置、姿勢、運動、個体関係に関する時空間特徴量を算出し、各行動の二値分類と隠れマルコフモデルを用いて、社会行動を検出した。検出結果として、攻撃、マウント、近接調査の 3 つの社会行動において、Precision と Recall とともに 0.85 から 0.9 を示し、人間のアノテーターと同等の精度で検出が可能となった。

このように、位置関係を用いた手法によって社会行動を高精度に検出可能であることが示され、その有効性が示唆された一方で、これらの研究は主に成体のみを対象としており、既存手法を成長過程の子を含む家族へ直接適用することは困難であると考えられる。

3. データ収集実験

3.1 動画像の収集

父、母、子の 3 個体で構成される烏骨鶏の家族を 3.0[m] × 1.5[m] の飼育柵に放ち、高さ 3[m] の天井から、飼育柵全体が映るように動画を撮影した (図 1)。動画像の収集は、30fps、解像度 768 × 432[px] で、1 日あたり約 7 時間 (消灯後の時間帯を一部含む) 行った。収集期間は 2025 年 6 月 5 日 (父母: 3 歳, 子: 1 週齢) から 7 月 22 日までの 48 日間であり、土日祝日を除いて 33 日分のデータを取得した。収集された動画像の総時間は 373 時間 18 分 43 秒であった。

3.2 社会行動の定義

本研究において検出対象とする社会行動は、approach, avoid, follow の 3 つであり、全て行動個体と相手個体の 2 個体間の行動として定義する。3 個体からなる家族の場合、行動個体と相手個体の方向を区別した方向ペア (行動個体, 相手個体) の組み合わせは (父, 母), (父, 子), (母, 父), (母, 子), (子, 父), (子, 母) の 6 通りとなる。本研究では、相手個体の体長の 1.5 倍の範囲を周辺エリアとし、周辺エリアを基準として各社会行動を定義した (表 1, 図 2)。




図 1: 動画像の収集条件

表 1: 社会行動の定義

社会行動	定義
approach	近づき始めてから周辺エリアに侵入するまで
avoid	周辺エリアを出てから移動が停止または緩やかになるまで
follow	周辺エリア内で追従を開始してから周辺エリアを出るまたは移動が終了するまで



図 2: 社会行動の定義




図 3: 収集した社会行動ラベル: a) クラスごとのフレーム数, b) 社会行動の区間長 [frame]

3.3 社会行動ラベルの付与

社会行動ラベルの付与は動物行動学の専門家 (第三著者) が実施した。まず、連続録画された動画像から社会行動を含む区間を選定するため、目視により社会行動の発生が確認された箇所を中心に前後 1 分間を切り出した。対象期間は 6 月 5 日から 6 月 24 日 (13 日分) とし、各日約 10 分間、計 129 分間の動画像を得た。そして、抽出した動画像に対して、各ペアについて 3 つの社会行動区間のラベル付与を行い、どの社会行動にも該当しない区間を other とした。付与された社会行動ラベルの結果を図 3 に示す。付与したラベルには other が大多数を占めるクラス不均衡が生じていることが確認された。また、各社会行動間だけでなく同一社会行動内でも区間長のばらつきが大きく、様々な時間スケールを考慮する必要があることが示唆された。

4. 提案手法

4.1 概要

図 4 に提案手法の概要を示す。提案手法は、動画像から各個体の位置情報を抽出する位置情報抽出と、得られた位置関係に基づいて社会行動を検出する社会行動検出の 2 段階で構成される。




図 4: 社会行動検出手法の概要

位置情報抽出では、まず初日のデータに対して SAM2 を用いて半自動的に正解マスクラベルを生成し、事前学習済みのマスク化モデルをファインチューニングする。2 日目以降に同一のモデルを用いた場合に、子の成長に伴う外見変化 (図??) によって検出精度が低下することが予想される。このため、段階的自己学習によって各日用のモデルを再構築し、初日分のアノテーションのみで長期間のトラッキングを実現する。構築したモデルにより各個体の重心情報と輪郭点情報を抽出し、カルマンフィルタによる平滑化を施す。

社会行動検出では、得られた各個体間の位置関係から時系列特徴量とその統計量を算出した集約特徴量を抽出し、フレーム単位で行動进行分类するモデルを構築する。さらに、分類モデルの出力に対して隠れマルコフモデル (HMM) による平滑化を施し、連続した同一予測ラベルをグループ化することで社会行動区間として検出する。




図 5: 子の成長に伴う外見変化の例：a) 初日, b) 2 週間後




図 6: 自己学習を用いた段階的ドメイン適応

4.2 位置情報の抽出

4.2.1 正解マスクラベルの生成

本研究では、SAM2 を用いて各個体に対するマスク情報のアノテーションを行うことで、アノテーションコストを抑える工夫を施した。まず、動画画像からランダムかつ重複なくフレーム画像を抽出し表示する。表示された画像上で各個体をクリックすることで、ポジティブプロンプト (対象物体の内部を示す点) を与える。SAM2 はこのプロンプトに基づいて個体のセグメンテーションを行い、その結果をリアルタイムで出力する。各個体のセグメンテーション結果を確認後、最大輪郭をポリゴン化し、正解マスクラベルとする。この手法により、1 フレームあたり約 3 回 (各個体 1 回) のクリック入力でアノテーションが可能となる。

4.2.2 自己学習を用いたドメイン適応

成長過程を含む長期間を対象として解析を行う場合、子の成長による外見変化によって、トラッキングの精度が低下することが予測される。加えて、全日付のデータに対し

てアノテーションを行う場合、アノテーションコストが膨大になる。そのため、本研究では段階的自己学習 [23] によってアノテーションコストを最小限に抑え、子の成長による外見変化に適応したトラッキング手法を構築する。

自己学習の流れを図 6 に示す。ある日付 T の動画画像を入力として、前日のデータでファインチューニングしたモデル M_{T-1} により各個体の予測を行う。このとき、信頼度が閾値以上のものを選択し、疑似マスクラベルとする。次に、得られた疑似マスクラベルをプロンプトとして SAM2 に与え、マスクを精緻化する。これにより自己学習によるマスクのエラー蓄積を軽減する。そして、生成された疑似マスクラベルを正解マスクとして M_{T-1} をファインチューニングし、 M_T を構築する。このプロセスを繰り返すことで、各日用のモデルを構築し、初日のデータに対するアノテーションのみで成長過程の子を含めた家族を継続的にトラッキングする。

表 2: 時系列特徴量一覧

カテゴリ	次元	特徴量
位置特徴 (P)	4	重心座標 (x, y) (行動・相手個体)
移動特徴 (M)	12	速度, 速度差分 (行動・相手個体) 加速度, 加速度差分 (行動・相手個体) 輪郭点移動量 (行動・相手個体)
社会特徴 (S)	10	重心距離, 重心距離差分 輪郭間最小距離, 輪郭間最小距離差分 接近指向性, 接近指向性差分 (行動・相手個体) 方向一致度, 方向一致度差分

4.3 社会行動の検出

4.3.1 特徴量の抽出

4.2 節で抽出した位置情報を用いて社会行動を検出する。本研究では、位置特徴 (P)、移動特徴 (M)、社会特徴 (S) の 3 カテゴリからなる時系列特徴量を算出する (表 2)。なお、各特徴量の差分とは隣接フレーム間の変化量 $(f(t) - f(t-1))$ であり、特徴量の時間的変化を捉える。

位置特徴 (P) は、行動個体と相手個体それぞれの重心座標 (x, y) であり、2 個体分で計 4 次元となる。

移動特徴 (M) は、各個体の運動状態を表す特徴量であり、行動個体と相手個体のそれぞれについて算出する。速度はフレーム間の重心移動量、加速度はフレーム間の速度変化量として算出する。輪郭点移動量は、マスクの全輪郭点におけるフレーム間の平均移動量であり、重心移動だけでは捉えられない姿勢変化を含む動きを反映する。これらは行動個体・相手個体の両方について算出し、各差分と合わせて計 12 次元となる。

社会特徴 (S) は、2 個体間の位置関係および運動の相互関係を表す特徴量である。重心距離は 2 個体の重心間のユークリッド距離、輪郭間最小距離は 2 個体のマスク輪郭間の最短距離である。接近指向性は、ある時刻 t における個体の速度ベクトルと相手個体までの位置ベクトルとのコサイン類似度であり (式 (1))、行動個体が相手個体に向かって移動しているほど高い値を示す。接近指向性は行動個体と相手個体の双方について算出する。方向一致度は、行動個体 A と相手個体 B の速度ベクトル同士のコサイン類似度である (式 (2))。各差分と合わせて計 10 次元となる。

$$\cos \theta_t^{A \rightarrow B} = \frac{\mathbf{v}_t^A \cdot (\mathbf{p}_t^B - \mathbf{p}_t^A)}{\|\mathbf{v}_t^A\| \|\mathbf{p}_t^B - \mathbf{p}_t^A\|} \quad (1)$$

$$\cos \phi_t^{AB} = \frac{\mathbf{v}_t^A \cdot \mathbf{v}_t^B}{\|\mathbf{v}_t^A\| \|\mathbf{v}_t^B\|} \quad (2)$$

また、得られた時系列特徴量に対して統計量 (平均値, 標準偏差, 中央値, 最大値, 最小値, 範囲 (=最大値-最小値), 合計) を算出し、集約特徴量として用いる。

4.3.2 分類モデル

4.3.1 項で抽出した特徴量を入力として、各フレームを 4 クラス (approach, avoid, follow, other) に分類するモデルを構築する。本研究では、特徴量の性質の違いを考慮

し、時系列特徴量を入力とする深層学習モデルと、集約特徴量を入力とする機械学習モデルの両者を構築し比較する。深層学習モデルとしては Bidirectional Long Short-Term Memory (BiLSTM) および Transformer (TF) を用いる。BiLSTM は過去と未来の両方向から時系列の依存関係を考慮可能であり、行動境界前後の文脈を反映できることから、時間構造を有する社会行動の分類に適すると考える。TF は自己注意機構により系列内の任意の 2 時点間の依存関係を直接モデル化可能であり、長距離の時間関係を捉えることが期待される。機械学習モデルとしては LightGBM (LGBM) および Random Forest (RF) を用いる。これらは決定木ベースのアンサンブル学習手法であり、特徴量間の非線形な関係や交互作用を表現できる点から選定した。

4.3.3 社会行動区間の検出

学習したモデルが出力するフレーム単位のクラス事後確率に対し、後処理を施すことで社会行動区間として検出する。本研究では、Segalin ら [12] の手法を参考に、隠れマルコフモデル (HMM) による平滑化を採用する。other を含む 4 つの社会行動ラベルを状態とする HMM を定義し、正解ラベル系列から状態遷移確率行列および初期状態分布を推定したうえで、分類器が出力する社会行動事後確率を出力確率として Viterbi アルゴリズムにより最尤状態系列を推定する。これにより自然な行動遷移を考慮した補正が可能となり、孤立した誤予測が周囲のラベルに合わせて修正されると考えられる。その後、平滑化後のフレーム系列から連続した同一予測ラベルをグループ化することで社会行動区間として検出する。

5. 性能評価実験

5.1 評価指標

本研究では、位置情報抽出と社会行動検出の両方の評価において、予測領域と正解領域の一致度を測る指標として Intersection over Union (IoU) を用いる (図 7)。IoU は式 (3) で定義され、0 から 1 の値をとり、1 に近いほど一致度が高い。

$$\text{IoU} = \frac{|A \cap B|}{|A \cup B|} \quad (3)$$

位置情報抽出の評価では A, B はそれぞれ予測マスクと正解マスクの空間領域、社会行動検出の評価では予測区間と正解区間の時間領域に対応する。




図 7: IoU の定義

位置情報抽出手法の評価では、段階的自己学習によって構築した各日のモデルが、長期間にわたり各個体を正確にセグメンテーション可能であるかを検証するため、mAPを用いる。mAPは、父、母、子の3クラスについて算出したAverage Precision (AP)の算術平均である。APは、予測マスクと正解マスクのIoUが閾値以上である予測を真陽性 (TP)、閾値未満または正解と対応しない予測を偽陽性 (FP)、対応する予測が存在しない正解マスクを偽陰性 (FN) とした際の Precision-Recall 曲線下の面積として定義される。本研究では、IoU 閾値を 0.5 に固定した mAP_{50} と、IoU 閾値を 0.5 から 0.95 まで変化させた際の mAP の平均値である $mAP_{50:95}$ を用いる。 mAP_{50} は個体の検出可否を、 $mAP_{50:95}$ はマスク境界の精度を含む総合的なセグメンテーション性能を評価する。

社会行動検出手法の評価は区間単位の F1 スコアで行う。予測区間と正解区間の IoU が一定の閾値以上である場合に正しい検出 (TP_i) とみなし、正解区間と一致しなかった予測区間を FP_i 、対応する予測が存在しない正解区間を FN_i として、各クラス i の Precision, Recall, F1 スコアを式 (4)～式 (6) により算出する。

$$Precision_i = \frac{TP_i}{TP_i + FP_i} \quad (4)$$

$$Recall_i = \frac{TP_i}{TP_i + FN_i} \quad (5)$$

$$F1_i = \frac{2 \times Precision_i \times Recall_i}{Precision_i + Recall_i} \quad (6)$$

さらに、社会行動全体の検出精度を表す指標として、各クラスの F1 スコアの算術平均であるマクロ F1 スコアを用いる。なお、other は評価対象から除外し、approach, avoid, follow の3クラスを対象とする。マクロ F1 スコアは式 (7) で定義される。ここで、 $C = 3$ は評価対象クラス数である。

$$Macro\ F1 = \frac{1}{C} \sum_{i=1}^C F1_i \quad (7)$$

5.2 位置情報抽出手法の評価

提案した位置情報抽出手法の有効性を検証するため、他の手法との比較実験を行った。比較対象として、(1) 初日のデータで学習したモデルを各日に対して直接適用するベースライン (Source)、(2) SAM2 による疑似マスクの精緻化を伴う自己学習を用いる提案手法 (SAM2-ST)、(3) SAM2 による精緻化を行わず前日モデルの予測のみを疑似マスクラベルとして自己学習する手法 (ST)、(4) 各日の正解マスクラベルで日々ファインチューニングする手法 (Oracle) の計4手法を設定した。ここで、Oracleを本研究における性能上界とする。結果を図8に示す。

図8より、Sourceは、 mAP_{50} 、 $mAP_{50:95}$ ともに日数の経過に伴って性能が漸減した。STは mAP_{50} では他手法と




図 8: 位置情報抽出手法の比較結果

同水準を維持した一方、 $mAP_{50:95}$ は最終日には初日から約0.3ポイント低下した。一方、提案手法であるSAM2-STは全期間にわたり、 mAP_{50} と $mAP_{50:95}$ の両指標で、各日の正解マスクラベルで日々ファインチューニングしたOracleと同程度の精度を維持した。

5.3 社会行動検出手法

5.3.1 実験設定

社会行動検出手法を検証する際の位置情報抽出手法には提案手法 (SAM2-ST) を用いた。実装には Python 3.10.19, PyTorch 2.6.0 (CUDA 12.4), scikit-learn 1.7.2, LightGBM 4.6.0 を用いた。特徴量抽出時の最大ウィンドウ幅は、全社会行動の99%が収まる長さである300フレームとした。

機械学習モデル (LGBM, RF) では、60, 150, 300 フレームの3種類のウィンドウ幅で集約特徴量を抽出し、それらを結合したマルチウィンドウ特徴量を入力とした。なお、ハイパーパラメータチューニングは行わない。深層学習モデル (BiLSTM, TF) では、300 フレームをチャンク長とし、オーバーラップ率0.5で重複するフレームの logits の平均をとることで予測を統合した。損失関数には式 (8) に示すクロスエントロピー損失を用いた。

$$\mathcal{L}_{CE} = -\frac{1}{T} \sum_{t=1}^T \sum_{c=1}^C y_{t,c} \log \hat{y}_{t,c} \quad (8)$$

ここで、 T はフレーム数、 C はクラス数、 $y_{t,c}$ はフレーム t におけるクラス c の正解ラベル、 $\hat{y}_{t,c}$ はモデルの予測確率を表す。各モデルのハイパーパラメータを表3に示す。

評価には10分割交差検証を用い、各モデルと特徴量の組み合わせ、HMMによる後処理の有無の条件でマクロ F1 スコア (IoU 閾値 0.1) を算出する。データリーク防止のため、全動画 (134 クリップ) をクリップ単位でランダムに

表 3: 分類モデルの設定

	BiLSTM	Transformer
隠れ層次元	64 (×2 双方向)	128
層数	2	4
Attention heads	—	4
FFN 次元	—	512
共通	Adam, lr=10 ⁻³ , batch=32, 30 epochs	

10 分割し、各フォールドを順にテスト、残り 9 のフォールドを学習データとする。これにより、同一の時系列データから正解データとテストデータに分割されることを防ぐ。なお、深層学習モデルでは学習フォールドの 9 割を訓練データ、残り 1 割を検証データとする。

複数の観点（HMM の有効性、モデル間の比較、特徴量の必要性）について多重比較を行うため、有意差検定には各フォールドを 1 サンプルとした Wilcoxon の符号付順位検定を採用し、Benjamini-Hochberg 法による多重比較補正を適用する。以降の図表内の*, **はそれぞれ補正後 $p_{adj} < 0.05$, $p_{adj} < 0.01$ を表す。

5.3.2 全体結果

10 分割交差検証における各条件のマクロ F1 スコアを図 9 に示す。結果から BiLSTM と HMM (M+S) がマクロ F1 スコア 0.654 で最大値を示したことが確認された。以降、この条件を最良モデルとして位置づけ、その妥当性を a) HMM の有効性、b) モデル選定、c) 特徴量選定の 3 つの観点から検証する。

5.3.3 HMM による後処理の有効性

各モデルにおける HMM 適用後最良の特徴量を選定し、同一特徴量間でのマクロ F1 スコアを HMM 適用前後で Wilcoxon 符号付順位検定により比較した。結果、BiLSTM, LGBM, TF では精度が有意に向上したことが確認された一方、RF は HMM の適用によって精度が有意に低下したことが示された。

以上より、BiLSTM において HMM による後処理は精度向上に有意に寄与することが示され、HMM の適用は妥当であると言える。

5.3.4 モデル間の比較

HMM 適用後の最良特徴量であった M+S において、最良モデル BiLSTM+HMM と他 3 モデル+HMM を Wilcoxon 符号付順位検定で比較した。BiLSTM+HMM は RF+HMM と比較して有意に精度が向上したことが示された一方、LGBM+HMM および TF+HMM に対しては有意差が確認されず、BiLSTM, LGBM, TF は同等の精度を示した。したがって、以降の検証では最上位群 (BiLSTM, LGBM, TF) の一つとして BiLSTM を用いる。

5.3.5 特徴量の選定

BiLSTM+HMM において、特徴量の組み合わせ全 21 対の有意差を Wilcoxon 検定により評価した。結果を表 4 に

表 4: BiLSTM+HMM の特徴量間での有意差検定結果

	P	M	S	P+M	P+S	M+S	P+M+S
P	0.13	n.s.	**	**	**	**	**
M	-	0.13	**	**	**	**	**
S	-	-	0.64	**	*	n.s.	n.s.
P+M	-	-	-	0.48	**	**	**
P+S	-	-	-	-	0.60	*	n.s.
M+S	-	-	-	-	-	0.65	n.s.
P+M+S	-	-	-	-	-	-	0.64

示す。表の対角成分は各特徴量の組み合わせにおける平均マクロ F1 スコア、上三角成分は行と列の特徴量間の有意差検定結果を表す。

対角成分より、S を含む特徴量 {S, P+S, M+S, P+M+S} は S を含まない特徴量 {P, M, P+M} と比較して高い精度を示した。上三角成分の検定結果から、S 単体は S を含まない特徴量 {P, M, P+M} に対していずれも有意に高い精度を示した。一方、S 単体と S を含む組み合わせである {M+S, P+M+S} の間には有意差が認められなかった。また、P+S は S 単体に対して有意に劣ることが示された。

以上から、BiLSTM+HMM では社会特徴 S のみで S を含む他の組み合わせと同等の精度が得られることが示され、解釈性や計算効率の観点から S 単体を用いることが妥当であると言える。したがって、以降の分析では BiLSTM+HMM において社会特徴 S 単体を用いる。

5.3.6 IoU 閾値による精度評価

IoU 閾値を増加させることは、予測区間と正解区間の時間的な一致をより厳密に評価することを意味し、区間境界の正確性を評価できる。BiLSTM+HMM+S における、各 IoU 閾値での F1 スコアを図 10 に示す。結果から、IoU 閾値が増加するにつれて全ての社会行動の検出精度が低下していく傾向が確認された。特に、IoU 閾値を 0.5 以上に設定した場合、マクロ F1 スコアは IoU 閾値が 0.1 の場合の半分程度まで低下することが示された。また、IoU 閾値が 0.7 の場合は各社会行動の F1 スコアが約 0.1 に収束し、検出が困難な状態となった。

5.4 ドメインシフトの検証

提案手法を新たな家族や個体の組み合わせに適用する際、ペアごとの社会行動ラベルの付与や再学習が不要であることが望ましい。しかし、本研究のように体格・週齢・性別が異なる個体間を対象とする場合、個体ペアごとに行動の出現頻度や時空間的特性が異なるドメインシフトが存在する可能性があり、未学習ペアへの汎化性能が低下する恐れがある。そこで本節では、無向ペア間のドメインシフトの有無とその要因を定量的に検証する。

検証には Leave-One-Pair-Out (LOPO) を用いる。LOPO は未学習のペアに対する汎化性能を評価することが可能である。本研究では、3 個体から構成される 6 つの方向ペア




図 9: 10 分割交差検証における各条件での平均マクロ F1 スコア




図 10: 各閾値における F1 スコア (BiLSTM+HMM+S)

(行動個体, 相手個体) のうち, 同一の 2 個体からなる方向ペアの組 (無向ペア: 父-母, 父-子, 母-子の 3 組) を単位とする. 無向ペアを単位とするのは, 同一の 2 個体からなる逆方向のペアは同じ個体間の相互作用に基づいて社会特徴が算出され, 一方を学習データに含めるとデータリークが生じるためである. LOPO では, 1 組の無向ペアに属する 2 方向ペアをテストデータ, 残り 4 方向ペアを学習データとする.

本節では, (1)LOPO における精度の比較, (2) 無向ペア間のクラス分布の検証, (3) クラス条件付き Maximum Mean Discrepancy (MMD) [31] による特徴分布差の検証の 3 段階で検証する. LOPO で精度が低下した場合, その要因がクラス分布の偏りか特徴分布のずれかは LOPO 単独では判別が困難であるため, (2)(3) で段階的に検証する.

5.4.1 LOPO の結果

BiLSTM+HMM+S を用いて LOPO におけるマクロ F1 スコア (IoU 閾値 0.1) を評価した. 結果を表 5 に示す. なお, 分類モデル自体は 10 分割交差検証と同様に 4 クラス

表 5: LOPO におけるマクロ F1 スコア (IoU 閾値 0.1)

方向ペア	方向別 F1	無向ペア	フォールド F1
父 → 母	0.55	父-母	0.46
母 → 父	0.35		
父 → 子	0.46	父-子	0.54
子 → 父	0.55		
母 → 子	0.63	母-子	0.61
子 → 母	0.59		
3 フォールド平均 ± 標準偏差		0.53 ± 0.078	

(approach, avoid, follow, other) 分類であり, other は評価対象から除外する. 表中のフォールド F1 は各無向ペアをテストデータとした際の平均マクロ F1 スコア, 方向別 F1 はテストデータを方向ペアごとに分割して算出した平均マクロ F1 スコアを表す.

結果から, 平均マクロ F1 スコアは 0.53 であり, 同一構成での 10 分割交差検証時の 0.64 と比較して 0.11 ポイント低下した. 母-子では 0.61 である一方, 父-母では 0.46 と, ペア間の大きな精度差が確認された. また無向ペア内でも方向ペア間で差が見られ, 父-母ペア内の父 → 母 (0.55) と母 → 父 (0.35) では約 0.2 ポイントの差が生じた.

以上から, 特定のペアでは 10 分割交差検証と同等の精度を維持する一方, 他のペアでは大きく劣化しており, 未学習ペアに対する汎化性能にはばらつきが存在することが確認された. ただし, 精度差は, 無向ペア間のクラス分布の偏りと同一クラス内における特徴分布のずれのいずれの要因によっても生じうる. そのため, 以降の項ではこれらの要因を切り分け, ドメインシフトの有無を検証する.

5.4.2 無向ペア間のクラス分布

表 6 に各無向ペアにおける社会行動の区間数を示す. 表から, approach および avoid は全ペアで一定の区間数を有

表 6: 無向ペアごとのクラス別区間数

無向ペア	approach	avoid	follow
父-母	182	162	20
父-子	136	124	12
母-子	277	257	164

する一方, follow は父-子で 12 区間, 父-母で 20 区間と相対的に少なく, 無向ペア間で不均衡が確認された. ペア間における顕著な不均衡は分布比較の信頼性を損なう可能性があるため, 分布解析では全ペアで一定の区間数が確保可能な approach, avoid のみを対象とする.

5.4.3 クラス条件付き MMD² の算出手法

MMD²[31] は 2 つの分布間の差を測るノンパラメトリック尺度であり, 特性カーネルを用いることで $\text{MMD}^2(P, Q) = 0 \Leftrightarrow P = Q$ が成り立つ. 本研究では, 特性カーネルの一つである RBF カーネル $k(x, y) = \exp(-\|x - y\|^2 / (2\sigma^2))$ を用い, バンド幅 σ^2 は全フレーム対のユークリッド距離 2 乗の中央値で決定した.

社会行動はフレーム連続区間 (bout) として現れ, bout 内のフレームは時間的相関が強く独立サンプルとして扱うことが困難である. そのため, bout 単位の MMD² を採用する. まず, $\mathbf{x}_t^{(i)}$ を bout i におけるフレーム t の特徴量ベクトルとし, T_i を bout i のフレーム数として, 2 つの bout $b = \{\mathbf{x}_t^{(b)}\}_{t=1}^{T_b}$, $b' = \{\mathbf{x}_s^{(b')}\}_{s=1}^{T_{b'}}$ 間のカーネルを式 (9) で定義する. なお, 特徴量 $\mathbf{x}$ は社会特徴 $\mathbf{S}$ を標準化した 10 次元ベクトルである.

$$K_{\text{bout}}(b, b') = \frac{1}{T_b T_{b'}} \sum_{t=1}^{T_b} \sum_{s=1}^{T_{b'}} k(\mathbf{x}_t^{(b)}, \mathbf{x}_s^{(b')}) \quad (9)$$

次に, n_d をペア d の bout 数として, 無向ペア d かつクラス $c \in \{\text{approach}, \text{avoid}\}$ に属する bout 集合 $\mathcal{B}_d = \{b_i\}_{i=1}^{n_d}$, $\mathcal{B}_{d'} = \{b'_j\}_{j=1}^{n_{d'}}$ を独立単位とし, K_{bout} を基底カーネルとした対角項除外の不偏 MMD² 推定量 [31] を式 (10) により算出する.

$$\begin{aligned} \text{MMD}_c^2(d, d') = & \frac{1}{n_d(n_d - 1)} \sum_{i \neq j} K_{\text{bout}}(b_i, b_j) \\ & + \frac{1}{n_{d'}(n_{d'} - 1)} \sum_{i \neq j} K_{\text{bout}}(b'_i, b'_j) \\ & - \frac{2}{n_d n_{d'}} \sum_{i, j} K_{\text{bout}}(b_i, b'_j) \end{aligned} \quad (10)$$

推定値の不確実性と分布差の有意性を以下の 2 手法で評価する. (i) bout 集合に対する 3,000 回のノンパラメトリック・ブートストラップにより母集団 $\text{MMD}_c^2(d, d')$ の 95% 信頼区間 (CI) を算出する. (ii) 帰無仮説 $H_0: P_d^c = P_{d'}^c$ を検定するため, 2 つの無向ペアの全 bout を統合してペアラベルを 3,000 回ランダムに入れ替え, 各試行で MMD² 値を計算し経験分布を構築する. 観測値以上の値が経験分布に出現する割合を p 値とし, CI が 0 を含まず $p < 0.05$

表 7: approach における MMD², 95%信頼区間, p 値

ペア対		approach		
d	d'	MMD ²	95% CI	p
父-母	父-子	0.022	[0.016, 0.033]	<0.001
父-母	母-子	0.050	[0.041, 0.062]	<0.001
父-子	母-子	0.006	[0.004, 0.013]	<0.001

表 8: avoid における MMD², 95%信頼区間, p 値

ペア対		avoid		
d	d'	MMD ²	95% CI	p
父-母	父-子	0.035	[0.024, 0.053]	<0.001
父-母	母-子	0.056	[0.044, 0.075]	<0.001
父-子	母-子	0.003	[0.001, 0.011]	0.024

である場合にドメイン間で有意差あり ($\alpha = 0.05$) とする.

5.4.4 クラス条件付き MMD² の算出結果

approach と avoid における無向ペア間のクラス条件付き MMD², 95%信頼区間, p 値をそれぞれ表 7, 表 8 に示す.

結果から, approach および avoid の両クラスにおいて, 3 組すべてのペア対で CI が 0 を含まず, かつ $p < 0.05$ であった. approach では (父-母と母-子) で MMD² が最大となり, (父-子と母-子) で MMD² が最小となった. avoid でも同様の傾向を示した. これらの結果から, 同一クラスであっても無向ペア間で特徴分布が統計的に有意に異なることが確認された.

さらに, 3 組のペア対における共通個体に着目すると, 子が共通するペア対 (父-子と母-子) の MMD² が両クラスで最小である一方, 母が共通するペア対 (父-母と母-子) の MMD² が最大となったことから, 母が関わる場合に特徴分布の差が大きくなる傾向が示された.

5.4.5 ドメインシフトに寄与する特徴量

無向ペア間のドメインシフトに寄与する社会特徴量を特定するため, 各 bout 内の特徴量平均値を 1 サンプルとし, 無向ペアを要因とする一元配置分散分析を行った. 効果量 η_k^2 は特徴量 k の bout 平均値の総分散のうち無向ペア間の平均差で説明される割合として定義される. approach と avoid において η^2 が上位の特徴量を表 9 に示す.

結果から, 重心距離の η^2 が両クラスで最大であり, 他特徴量と比較して大きい値を示した. ただし, η^2 は特徴量ごとの周辺分布における平均差のみを示し, 多変量分布における寄与を示さない. そこで, 重心距離を除いた 9 次元社会特徴量で 5.4.3 項と同手順により多変量 MMD² を再算出した. その結果を表 10, 表 11 にそれぞれ示す.

結果から, 全 6 比較で MMD² が 54–90% 減少したことから, 重心距離が無向ペア間のドメインシフトに大きく寄与する特徴量であったことが示唆された. 一方, 6 比較中 5 比較では CI が 0 を含まずかつ $p < 0.05$ が維持され, 重心距離以外の特徴量にもペア間のドメインシフトが存在す

表 9: 一元配置分散分析による上位社会特徴量

approach		avoid	
特徴量	η^2	特徴量	η^2
重心距離	0.293	重心距離	0.256
輪郭間最小距離	0.036	輪郭間最小距離差分	0.035
方向一致度	0.026	輪郭間最小距離	0.029

表 10: approach における重心距離除外時の MMD², 95%信頼区間, p 値, 減少率

ペア対		approach			
d	d'	MMD ²	95% CI	p	減少率
父-母	父-子	0.003	[0.001, 0.010]	0.013	86%
父-母	母-子	0.009	[0.005, 0.017]	<0.001	82%
父-子	母-子	0.002	[0.000, 0.008]	0.045	74%

表 11: avoid における重心距離除外時の MMD², 95%信頼区間, p 値, 減少率

ペア対		avoid			
d	d'	MMD ²	95% CI	p	減少率
父-母	父-子	0.003	[0.001, 0.013]	0.030	90%
父-母	母-子	0.010	[0.006, 0.019]	<0.001	83%
父-子	母-子	0.001	[0.000, 0.009]	0.114	54%

表 12: 重心距離除外による精度変化

特徴量次元	LOPO	10 分割
社会特徴 S (10 次元)	0.53 $\pm$ 0.064	0.64 $\pm$ 0.061
重心距離除外 (9 次元)	0.55 $\pm$ 0.017	0.62 $\pm$ 0.054

ることが示された。

5.4.6 重心距離を除外した精度評価

5.4.5 項より, 重心距離が無向ペア間のドメインシフトに大きく寄与する特徴量として特定された。そこで, BiLSTM+HMM+S の入力から重心距離を除いた 9 次元社会特徴量で再学習し, LOPO および 10 分割交差検証における精度変化の検証を行った。その結果を表 12 に示す。

結果から, LOPO では標準偏差が 0.064 から 0.017 へと約 1/4 に縮小し, 未知ペアに対する精度と安定性が向上した一方, 10 分割交差検証では平均マクロ F1 スコアが 0.022 ポイント低下したことが確認された。

6. 考察

本章では, 5 章の結果に基づき, 位置情報抽出手法の有効性, HMM による後処理の有効性, 区間検出の精度限界, 無向ペア間ドメインシフトの 4 つの観点から考察を行う。

6.1 位置情報抽出手法の有効性

図 8 より, 提案手法の SAM2-ST は全期間にわたり各日の正解ラベルで学習した Oracle とほぼ同等の精度を維持した一方, Source は日数経過に伴い精度が漸減し, ST は

mAP₅₀ は他手法と同水準を維持したものの mAP_{50:95} は最終日には初日から約 0.3 ポイント低下した。

Source の精度低下は, 子の急速な成長に伴う外見変化により, 初日のデータのみで学習したモデルでは後日の入力分布に追従できなかったことに起因すると考えられる。これは外見変化が連続的に生じる長期間のトラッキングにおいて, 固定モデルが不適切であることを示している。

一方, ST は前日モデルの予測をそのまま疑似マスクラベルとして再学習するため, 個体の大まかな位置 (小さい IoU 閾値での検出) の検出精度は維持可能である一方, マスク境界の誤りが日次で蓄積し, 高い IoU 閾値において精度が低下したと考えられる。これは段階的自己学習において, 疑似ラベル自体の品質劣化が連鎖的に伝搬する一般的な問題と合致する。

これに対し, 提案手法の SAM2-ST は前日モデルの予測をプロンプトとして SAM2 に与え, マスク境界を精緻化したうえで疑似マスクラベルを生成する。SAM2 の強力な事前知識によって各日で疑似ラベルの品質が再保証されるため, 誤りの伝搬が抑制されたと考えられる。加えて, 日次の段階的適応により隣接ドメイン間の差が小さく保たれることは, 密に配置された中間ドメインを選ぶほど精度が改善するという Wang ら [25] の知見と整合する。

以上より, 初日のアノテーションのみで成長過程を含む長期間にわたり Oracle 相当の追跡精度を達成できることが示され, アノテーションコストと精度のトレードオフを大きく改善した点で本手法の有効性が示唆された。

6.2 HMM による後処理の有効性

5.3.3 項の結果より, BiLSTM, LGBM, TF において HMM の適用前後で有意な精度向上が確認された。社会行動は数百フレームの連続した区間として現れる一方, これらの分類器は BiLSTM や TF のように時間文脈を隠れ状態として学習する深層モデルであっても, 最終的な出力はフレーム単位の分類確率であり行動間の遷移を明示的にはモデル化していない。加えて社会行動特有の境界の曖昧さによって境界付近の予測にぶれが生じやすい。これに対し HMM は状態遷移確率を介して自然な行動遷移の情報を与え, Viterbi アルゴリズムが孤立した誤予測フレームを周囲と整合的に修正することで, 区間レベルの検出精度向上に寄与したと考えられる。

一方, RF は HMM 適用により有意な精度低下を示した。RF は決定木のアンサンブルであり, 葉ノードでのクラス頻度比をそのまま事後確率として出力するため, 事後確率が 0 や 1 に偏った極端な値を取る傾向がある。こうした分布は HMM の出力確率として与えた際に最適な経路の推定が困難となり, かえって誤りが伝搬したと考えられる。したがって, HMM による後処理を有効にするためには, 事

後確率が滑らかに分布するモデルを選定する必要がある。

6.3 区間検出の精度限界

5.3.6 項の結果より、IoU 閾値を 0.1 から 0.5 へ上昇させるとマクロ F1 が 0.65 から約半分に低下し、0.7 では約 0.1 まで低下することが確認された。この結果から、提案手法は社会行動の発生自体は概ね検出できる一方、区間の開始点・終了点の正確性には課題が残ることが示唆された。

この境界精度の低下要因として、以下の 3 点が考えられる。第一に、社会行動の境界の曖昧さが挙げられる。社会行動の解釈は人間同士であっても完全に一致させることは困難であり [11]、特に other を含めた場合のフレーム単位での一致度は約 7 割程度であったことが報告されている [13]。このことから、正解ラベル自体に不確実性が含まれている可能性がある。第二に、HMM の遷移確率行列はデータ全体の自己相関を平均化したものであり、行動境界における鋭敏な状態遷移を捉えることが困難となった可能性がある。第三に、本研究では社会行動ごとに区間長が大きく異なるにもかかわらず単一の遷移確率を共有しているため、区間長に対応した行動境界の推定が行えていない可能性が考えられる。

6.4 実用上の目標値とのギャップ

第 3 著者は、動物行動学の専門家としてラベル付けを行ったが、その際に区間境界に ± 1 秒程度のずれ（曖昧さ）が生じることは避けられないと考えている。そのため、一定のずれを許容したうえで、社会関係分析の用途として、(i) 発生頻度の記述ではマクロ F1 スコア 0.7 (IoU 閾値 0.1)、(ii) 区間内情報を活用した分析ではマクロ F1 スコア 0.6 (IoU 閾値 0.5) が実用上の目標値とされている。本手法は (i) の水準にほぼ到達した一方、IoU 閾値 0.5 ではマクロ F1 スコアが約 0.3 にとどまり、(ii) とは 0.3 ポイントのギャップが存在する。このギャップの解消には、6.3 項で述べた行動境界の推定精度の改善が不可欠である。

6.5 無向ペア間ドメインシフト

5.4 節の結果より、無向ペア間に統計的に有意なドメインシフトが存在することが示された。MMD は子が共通するペア対（父-子と母-子）で最小、子を含まないペア対が子を含むペア対と比較される場合に最大となり、子の存在がペアの社会特徴分布を強く規定する支配的要因であることが示唆された。また、重心距離の効果量 η^2 が両クラスで最大であり、重心距離を除外した場合、MMD² で分布距離が 54–90% 減少したことから、成体と子の体格差・運動能力差に起因する近接距離の違いが主要因と考えられる。

さらに、重心距離を除外した再学習では、LOPO の精度が向上し標準偏差が縮小する一方、10 分割交差検証の平均

精度が低下するトレードオフが確認された。重心距離は社会行動分類にも有用な情報を含むと考えることができ、単純な特徴量除去では未知ペアへの汎化と既知ペア内精度の両立が困難であることが示唆された。

以上より、未知のペアへの汎化に向けて以下の 2 つの方向が考えられる。第一に、敵対的ドメイン適応によるドメイン不変特徴の抽出、第二に、個体ごとの体長で正規化した特徴量設計。これらの手法は個体間の体格差・個体差を考慮する手法であり、個体差に依らない頑健な特徴量を抽出することで、汎化性能が向上することが期待される。

6.6 制約

本研究の知見を解釈する上での制約と、その拡張に向けた方針を述べる。

第一に、本研究は 1 家族（父、母、子それぞれ 1 個体）のデータに基づいており、得られた知見が他の家族にも成立するかは未検証である。家族ごとの個体差や関係性の違いが社会行動の特徴分布に影響を与える可能性があり、複数家族での検証が必要である。

第二に、本研究では子が 1 羽の家族構成のみを対象としている。子が複数羽の場合、成体-子のペアに加えて子同士（子 1→子 2 など）のペアが生じ、体格や運動能力が類似した個体間の社会行動を扱う必要がある。子同士のペアでは成体-子間とは異なるドメインシフトが生じる可能性があり、モデルの汎化性能や特徴量設計の再検討が求められる。

第三に、本研究では俯瞰カメラから得られるカメラ座標系上の位置情報をそのまま用いている。そのため、カメラの画角や設置高さが異なる環境では、同一の行動であっても特徴量の値が変化する。異なる撮影環境への適用には、実空間座標への変換やカメラパラメータに基づく正規化が必要となる。

7. おわりに

本研究では、動画像から抽出した位置関係に基づき、烏骨鶏の家族における長期的な関係性分析に向けた社会行動検出手法を提案した。まず、SAM2 による疑似マスクの精緻化を伴う段階的自己学習により、初日のアノテーションのみで子の成長による外見変化に対応したトラッキングを実現した。次に、抽出した位置情報から特徴量を算出し、分類モデルと HMM による後処理を組み合わせた社会行動検出手法を構築した。

評価の結果、トラッキングは各日の正解ラベルで都度学習した手法と同等の精度を維持し、社会行動検出では (BiLSTM+HMM+社会特徴量) の構成が 10 分割交差検証においてマクロ F1 スコア 0.65 (IoU 閾値 0.1) を達成した。HMM による後処理は深層学習および勾配ブースティングのいずれのモデルにおいても有意に精度を向上させた。ま

た, 1 ペア抜き交差検証およびクラス条件付き MMD² による分布解析により, ペア間に統計的に有意なドメインシフトが存在し, 特に母を含むペア間で大きいことを定量的に示し, 特徴量を保持したままドメインシフトを抑制する手法の必要性が示唆された。

また, 実用上の目標値との比較では, 発生頻度の記述に必要な水準にほぼ到達した一方, 区間内情報を活用する分析にはギャップが残ることを確認した。

今後は, 社会行動を区間として正確に検出する手法や個体差を考慮した特徴量設計・ドメイン適応手法の検討を通じて, 社会行動の検出精度の向上を図るとともに, より長期的な分析に向けたトラッキングの安定性の向上を目指す。また, 複数家族および子が複数羽の条件下でのデータ収集と検証を進め, 本手法の汎用性を確認する。さらに, 提案手法を用いて検出した社会行動区間内の速度情報や発生頻度などといった様々な情報を用いて養育期間における社会関係を定量化する手法の構築を目指す。

謝辞

本研究成果は, JSPS 科研費 (25K21743) および JST 研究成果展開事業 研究成果最適展開支援プログラム (A-STEP) JPMJTR24UG の支援を受けたものです。

参考文献

- [1] Van Anh Le, Toni-Lee Sterley, Ning Cheng, Jaideep S. Bains, and Kartikeya Murari. Markerless mouse tracking for social experiments. *eNeuro*, Vol. 11, No. 2, 2024.
- [2] Karen L. Bales. Parenting in animals. *Current Opinion in Psychology*, Vol. 15, pp. 93–98, 2017.
- [3] Lisa A. McGraw and Larry J. Young. The prairie vole: an emerging model organism for understanding the social brain. *Trends in Neurosciences*, Vol. 33, No. 2, pp. 103–109, 2010.
- [4] Tom Menaker, Joke Monteny, Lin Beeck, and Anna Zamansky. Clustering for automated exploratory pattern discovery in animal behavioral data. *Frontiers in Veterinary Science*, Vol. 9, p. 884437, 2022.
- [5] Jan Erik Doornweerd, Gert Kootstra, Roel F. Veerkamp, Esther D. Ellen, Jerine A. J. van der Eijk, Thijs van de Straat, and Aniek C. Bouwman. Across-species pose estimation in poultry based on images using deep learning. *Frontiers in Animal Science*, Vol. 2, No. 791290, 2021.
- [6] Shida Zhao, Zongchun Bai, Lili Meng, Guofeng Han, and Enze Duan. Pose estimation and behavior classification of jinling white duck based on improved hrnet. *Animals*, Vol. 13, No. 18, p. 2878, 2023.
- [7] C. Fang, Z. Wu, H. Zheng, J. Yang, C Ma, and T Zhang. Mcp: Multi-chicken pose estimation based on transfer learning. *Animals*, Vol. 14, No. 12, 2024.
- [8] Alexander Mathis, Pranav Mamidanna, Kevin M. Cury, Taiga Abe, Venkatesh N. Murthy, Mackenzie Weygandt Mathis, and Matthias Bethge. Deeplabcut: markerless pose estimation of user-defined body parts with deep learning. *Nature Neuroscience*, Vol. 21, No. 9, pp. 1281–1289, 2018.
- [9] Talmo D. Pereira, Nathaniel Tabris, Arie Matsliah, David M. Turner, Junyu Li, Shruthi Ravindranath, Eleni S. Papadoyannis, Edna Normand, David S. Deutsch, Z. Yan Wang, Grace C. McKenzie-Smith, Catalin C. Mitelut, Marielisa Diez Castro, John D’Uva, Mikhail Kislin, Dan H. Sanes, Sarah D. Kocher, Samuel S.-H. Wang, Annegret L. Falkner, Joshua W. Shaevitz, and Mala Murthy. Slep: A deep learning system for multi-animal pose tracking. *Nature Methods*, Vol. 19, No. 4, pp. 486–495, 2022.
- [10] Weizhe Hong, Ann Kennedy, Xavier P. Burgos-Artizzu, Moriel Zelikowsky, Santiago G. Navonne, Pietro Perona, and David J. Anderson. Automated measurement of mouse social behaviors using depth sensing, video tracking, and machine learning. *Proceedings of the National Academy of Sciences*, Vol. 112, No. 38, pp. E5351–E5360, 2015.
- [11] Nusret Ipek, Liesbeth G. W. Van Damme, Frank A. M. Tuytens, and Jan Verwaeren. Quantifying agonistic interactions between group-housed animals to derive social hierarchies using computer vision: a case study with commercially group-housed rabbits. *Scientific Reports*, Vol. 13, No. 1, p. 14138, 2023.
- [12] Cristina Segalin, Jalani Williams, Tomomi Karigo, May Hui, Moriel Zelikowsky, Jennifer J Sun, Pietro Perona, David J Anderson, and Ann Kennedy. The mouse action recognition system (mars) software pipeline for automated analysis of social behaviors in mice. *eLife*, Vol. 10, p. e63720, 2021.
- [13] Xavier P. Burgos-Artizzu, Piotr Dollár, Dayu Lin, David J. Anderson, and Pietro Perona. Social behavior recognition in continuous video. In *2012 IEEE Conference on Computer Vision and Pattern Recognition*, pp. 1322–1329, 2012.
- [14] Edoardo Fazzari, Donato Romano, Febrizio Falchi, and Cesare Stefanini. Animal behavior analysis methods using deep learning: A survey. *Expert Systems with Applications*, Vol. 289, p. 128330, 2025.
- [15] Yaning Han, Ke Chen, Yunke Wang, Wenhao Liu, Zhouwei Wang, Xiaojing Wang, Chuanliang Han, Jiahui Liao, Kang Huang, Shengyuan Cai, Yiting Huang, Nan Wang, Jinxiu Li, Yangwangzi Song, Jing Li, Guo-Dong Wang, Liping Wang, Yaping Zhang, and Pengfei Wei. Multi-animal 3d social pose estimation, identification and behaviour embedding with a few-shot learning framework. *Nature Machine Intelligence*, Vol. 6, No. 1, pp. 48–61, 2024.
- [16] Shaokai Ye, Anastasiia Filippova, Jessy Lauer, Steffen Schneider, Maxime Vidal, Tian Qiu, Alexander Mathis, and Mackenzie Weygandt Mathis. Superanimal pre-trained pose estimation models for behavioral analysis. *Nature Communications*, Vol. 15, No. 1, p. 5165, 6 2024.
- [17] Glenn Jocher, Ayush Chaurasia, and Jing Qiu. Ultralytics yolov8, 2023.
- [18] Kaiming He, Georgia Gkioxari, Piotr Dollár, and Ross Girshick. Mask r-cnn. In *Proceedings of the IEEE international conference on computer vision*, pp. 2961–2969, 2017.
- [19] Gaurav Kaul, Jonathan McDevitt, Justin Johnson, and Ada Eban-Rothschild. Damm for the detection and tracking of multiple animals within complex social and environmental settings. *Scientific Reports*, Vol. 14, No. 1, p. 21366, 2024.
- [20] Nikhila Ravi, Valentin Gabeur, Yuan-Ting Hu, Ronghang Hu, Chaitanya Ryali, Tengyu Ma, Haitham Khedr, Roman Rädle, Chloe Rolland, Laura Gustafson, Eric Mintun, Junting Pan, Kalyan Vasudev Alwala, Nicolas

- Carion, Chao-Yuan Wu, Ross Girshick, Piotr Dollár, and Christoph Feichtenhofer. SAM 2: Segment anything in images and videos. *arXiv preprint*, 2024.
- [21] Sarah Mele, Joshua Millward, Long Nguyen, Natasha Ruth, Jemma Gasperoni, Sebastian Dworkin, Zhen He, and Travis K. Johnson. A segment anything model-based tool for semi-automated behavioural analysis of drosophila and other model organisms. *Disease Models & Mechanisms*, p. dmm.052631, 2026.
 - [22] Yonggi CHo, Song Eungyeol, Ji Yeongiu, Yang Satebyeol, Kim Taehyun, Park Susang, Baek Doosan, and Yu Sunjin. Multi-cat monitoring system based on concept drift adaptive machine learning architecture. *Sensors*, Vol. 23, No. 21, 2023.
 - [23] Ananya Kumar, Tengyu Ma, and Percy Liang. Understanding self-training for gradual domain adaptation. In *Proceedings of the 37th International Conference on Machine Learning*, Vol. 119, pp. 5468–5479, 2020.
 - [24] Shiry Ginosar, Kate Rakelly, Sarah Sachs, Brian Yin, and Alexei A. Efros. A century of portraits: A visual historical record of american high school yearbooks. In *2015 IEEE International Conference on Computer Vision Workshop*, pp. 652–658, 2015.
 - [25] Haoxiang Wang, Bo Li, and Han Zhao. Understanding gradual domain adaptation: Improved analysis, optimal path and beyond. In *Proceedings of the 39th International Conference on Machine Learning*, Vol. 162, pp. 22784–22801, 2022.
 - [26] Tae-Yong Choi, Seah Jeong, and Ja Wook Koo. Mesocorticolimbic circuit mechanisms of social dominance behavior. *Experimental & Molecular Medicine*, Vol. 56, No. 9, pp. 1889–1899, 2024.
 - [27] Hannah E. Lapp, Melissa G. Salazar, and Frances A. Champagne. Automated maternal behavior during early life in rodents (amber) pipeline. *Scientific Reports*, Vol. 13, No. 18277, 2023.
 - [28] Jeanne Altmann. Observational study of behavior: Sampling methods. *Behaviour*, Vol. 49, No. 3-4, pp. 227–267, 1974.
 - [29] Gordon M. Burghardt, Jodie N. Bartmess-LeVasseur, Stevan A. Browning, Kimberly E. Morrison,Carolynn L. Stec, Christina E. Zachau, and Todd M. Freeberg. Perspectives – minimizing observer bias in behavioral studies: A review and recommendations. *Ethology*, Vol. 118, No. 6, pp. 511–517, 2012.
 - [30] David J. Anderson and Pietro Perona. Toward a science of computational ethology. *Neuron*, Vol. 84, No. 1, pp. 18–31, 2014.
 - [31] Arthur Gretton, Karsten M. Borgwardt, Malte J. Rasch, Bernhard Schölkopf, and Alexander Smola. A kernel two-sample test. *Journal of Machine Learning Research*, Vol. 13, No. 25, pp. 723–773, 2012.