動画解析により抽出した位置関係による烏骨鶏家族の社会行動の検出

岩本 純 †　髙野 耀希 ††　瀬口 瑛子 †††　新村 毅 †††　藤波 香織 † †† ††††
† 東京農工大学 工学部 知能情報システム工学科
†† 東京農工大学大学院 先進学際科学府 先進学際科学専攻　††† 東京農工大学 農学部 生物生産学科
†††† 東京農工大学 工学研究院 先端情報科学部門

1　はじめに

社会性を示す動物種において, 複数個体間の社会行動は普遍的に観察され, 社会行動の理解は生態学や神経科学において重要である [1]. しかしながら, 社会行動を目視で観察・記録することは, 多大な時間と労力を要求する. そういった背景から, 動物行動の自動分析に関する研究が進められ, 位置のトラッキングや単一個体の行動検出を高精度で行うことができるようになっている. しかしながら, 社会行動は単一個体の行動よりも複雑性が増し, 検出がより困難になる [2].

本研究では, 動画解析によって抽出される位置関係を用いて, 鶏の一種である烏骨鶏を対象として, 家族間における社会行動検出手法について報告する. なお, 烏骨鶏の家族間で頻発し, かつ重要な社会行動として, (1) 相手個体へ近づく行動 (approach), (2) 相手個体から離れる行動 (avoid), (3) 近距離を維持したまま相手個体を追う行動 (follow) の 3 つに着目する. さらに, この 3 つ以外をその他 (other) として加え, 計 4 行動の分類を行う.

2　社会行動検出手法

2.1　概略

図 1 に提案手法の概要を示す. まず, 上から撮影した動画に対して, インスタンスセグメンテーションモデルを用いて位置情報を抽出し, さらに社会行動特徴量を抽出する. 次に, 抽出した特徴量を用いて, 各社会行動に対する, フレーム単位の二値分類モデルを構築し, 社会行動確率分布を出力する. そして, 社会行動確率分布に対して, 時系列を考慮した平滑化を行う. 最後にグループ化処理を適用し, 社会行動区間の検出を行う.

2.2　位置情報の検出

位置情報抽出の流れを図 1 の上部に示す. 位置情報の抽出には, SAM2[3] と YOLO11[4] を併用した. SAM2 は学習なしでクリックした物体をセグメンテーション可能だが, 計算コストが大きく長時間動画への適用は非現実的である. 一方, YOLO11 は高速だが事前学習が必要となる. そこで, SAM2 へのクリック入力により正解ラベルを低コストで生成し, それを用いて YOLO11 をファインチューニングした. した. その結果, 各個体の検出精度において正解率 96.7% を示した.

次に, 事前学習済みの YOLO モデルを用いて動画データに対するインスタンスセグメンテーションを行う. そして, 得られた重心座標に対して線形補間と平滑化を施し, 重心情報と輪郭情報の 2 種類の位置情報を抽出する.

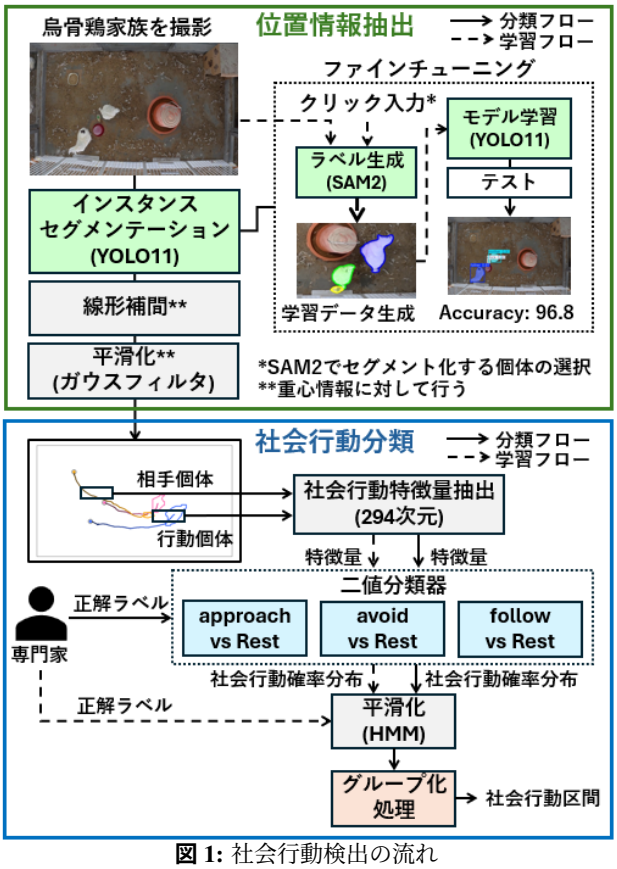

図 1: 社会行動検出の流れ

2.3　社会行動特徴量

まず, 時系列の位置情報から, 表 1 に示す計 14 種類の時系列特徴量を抽出する. 接近指向性は, 行動個体の速度ベクトルと, 相手個体への方向ベクトルとのコサイン類似度と定義した. また, 最近接輪郭距離は, 各個体の輪郭点群の中で最も近い点同士の距離と定義した.

次に, 多様な時間スケールにおける特徴を捉えるため, 3 種類の区間 (40 フレーム, 75 フレーム, 200 フレーム) を設定する. そして, 各区間内の時系列特徴量の統計量 (中央値, 平均, 標準偏差, 最大, 最小, 範囲, 合計) を算出する. 最終的に, 14 時系列特徴量 × 3 区間 × 7 統計量 = 294 次元の社会行動特徴量が各フレームで得られる.

2.4　フレーム単位の社会行動分類

社会行動分類の流れを図 1 の下部に示す. まず, 各フレームに対し, 各行動とそれ以外を分類する二値分類器をそれぞれ構築する. 分類モデルには LightGBM を用いる. また, クラス不均衡対策のため, SMOTE[5] を適

表 1: 特徴量一覧

カテゴリ	特徴量
空間的距離	重心間距離, 最近接輪郭距離
運動特徴	速度, 加速度, 相対速度, 輪郭総変化量
接近指標	接近指向性, 速度のコサイン類似度
時間変化	重心間距離変化, 最近接輪郭距離変化

Detection of Social Behavior in Silkie Fowl Families Using Video-Based Location Data

† Jun IWAMOTO　†† Yoki TAKANO　††† Akiko SEGUCHI　††† Tsuyoshi SHIMMURA　† †† †††† Kaori FUJINAMI
† Department of Electrical Engineering and Computer Science, Tokyo University of Agriculture and Technology, †† Graduate School of Advanced Interdisciplinary Science, Tokyo University of Agriculture and Technology, ††† Department of Biological Production, Tokyo University of Agriculture and Technology, †††† Division of Advanced Information Technology and Computer Science, Tokyo University of Agriculture and Technology

用し, クラス毎のサンプル数を揃える. 最終的に, 行動毎の事後分類確率を統合し, 社会行動確率分布を得る.

各フレームを独立に分類する場合, 数フレームの孤立した誤分類や生物学的に生じ得ない行動遷移が生じる可能性がある. この課題に対して Segalin らは, 隠れマルコフモデル (HMM) による平滑化を行い, 有効性を確認した [6]. そのため, 本研究においても, 平滑化に HMM を採用する. HMM によって推測される隠れ状態を, 社会行動ラベル { approach, avoid, follow, other}, 推測に用いられる観測変数を, 各フレームにおける社会行動確率分布とした. そして, 正解ラベルで HMM を学習し, 最適な隠れ状態列すなわち社会行動ラベル系列を推測する.

2.5 社会行動のグループ化処理

平滑化後のフレーム単位の予測結果にも局所的な誤分類が含まれるため, 単一の行動区間が過剰に分割されて検出される恐れがある. これを防ぐため, 行動区間を適切に統合して 1 つの行動区間として検出する必要がある. まず, フレーム毎に予測したラベルから, 連続した各予測ラベルをそれぞれグループ化し, 各行動区間として集約する. 次に, 同一ラベルの行動区間が 100 フレーム以内の間隔に存在する場合, それらを 1 つの区間として統合する. さらに, 統合処理後, 10 フレーム未満の短い区間が存在する場合はノイズとして除去する.

3 実験

3.1 データ収集

父, 母, 雛 (生後 1 週間) の 3 個体で構成される烏骨鶏の家族を 3.0[m] × 1.5[m] の飼育柵に放ち, 高さ 3[m] の天井から, 飼育柵全体が映るように動画を撮影した. 動画データは, 30fps, 解像度 768 × 432[px] で, 平日に 1 日約 7 時間, 計 1.5 か月間 (33 日分) 収集した. 本研究では, 最初の 10 日分のデータを対象として実験を行った.

次に, 目視で社会行動が観察された箇所の前後 1 分間を切り出し, 各日 10 分間, 計 100 分間の動画データを抽出した. そして, 専門家 (第 3 著者) が, 抽出した動画データに対して, 3 つの社会行動のラベル付けを行い, 対象の行動に該当しない区間を other とした.

3.2 精度検証

提案手法を, F1 スコアを精度指標として, フレーム単位の分類精度と行動区間の検出精度を検証した. 検証には, 5 分割交差検証を用いた. また, 目視によるラベル付けには変動性が存在する [7]. そのため, フレーム単位の分類において, 30 フレームまでのラグ (l) を許容した評価を実施し, 行動区間の検出においては, 正解区間と予測区間が 10%以上一致する場合に検出成功とした.

フレーム単位の分類精度の評価結果と, $l = 0$ と 30 における混同行列を, それぞれ表 2 と図 2 に示す. 表 2 から, $l = 30$ において, macro F1 スコアが 0.54 から 0.72 まで向上したことが示された. また, 図 2 より, $l = 0$ において, other と各社会行動間の誤分類が多いものの, $l = 30$ とすることで, other と各社会行動間のの誤分類が減少したことが確認された. また, $l = 0, 30$ のどちらにおいても社会行動間の誤分類が少ないことが示された.

行動区間の検出精度の評価結果と, グループ処理前後における, 雛から母への社会行動検出結果の一例を, それぞれ表 3 と図 3 示す. 表 3 から, グループ化処理の適用によって, macro F1 スコアが 0.41 から 0.56 まで向上したことが確認された. また, 図 3 より, グループ化処理前においては, 1 つの正解区間に対して複数の区間が予測されていたのに対し, 処理後においては, 複数の区間が統合され, 誤検出が抑えられたことが示された.

表 2: l を変化させた時の各行動の F1 スコア

l	approach	avoid	follow	other	macro F1
0	0.44	0.33	0.44	0.97	0.54
10	0.55	0.47	0.52	0.97	0.63
20	0.62	0.56	0.58	0.98	0.68
30	0.66	0.62	0.65	0.98	0.72

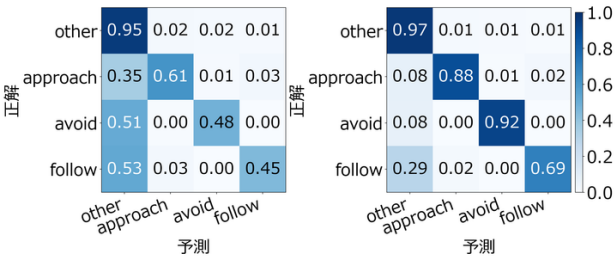

図 2: フレーム単位の混同行列 (左: $l = 0$, 右: $l = 30$)

表 3: グループ化処理前後における各行動区間の F1 スコア

行動	approach	avoid	follow	macro F1
処理前	0.50	0.40	0.33	0.41
処理後	0.62	0.54	0.51	0.56

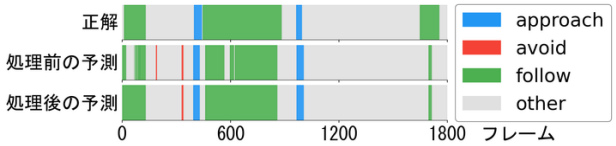

図 3: グループ化処理前後における各行動区間の検出結果

4 考察

3.2 節より, ラグを大きくすることで other との誤分類が改善されたことから, other と各行動の開始・終了時点の分離が困難であり, 検出に範囲誤差が生じた可能性が考えられる. 一方で, ラグを 30 フレーム (約 1 秒) 許容することで, 社会行動を分類できることが示唆された. また, ラグが 0 の場合においても, 社会行動間の誤分類が少ないことから, 本研究で導入した特徴量によって, 各社会行動の特徴を適切に捉えることができると考えられる. また, 連続したラベルを集約するだけでなく, 短い区間の統合やノイズ除去を行うことで, 行動区間の検出精度が向上することが示唆された.

5 おわりに

本研究では, 動画解析によって抽出した位置関係から, 3 つの社会行動を検出した. 結果, 行動区間の検出精度において, macro F1 が 0.56 であることが確認された. 本研究において, 専門家の分析に必要な行動区間の検出精度は約 0.7 であるため, 精度をより高める必要がある.

今後は, 社会行動区間の情報を用いて, 家族関係を定量化する手法について取り組む.

謝辞

本研究は, JSPS 科研費 (25K21743) および JST A-STEP (JPMJTR24UG) の支援を受けた.

参考文献

[1] E. Fazzari *et al.*, "Animal behavior analysis methods using deep learning: A survey," *Expert Syst. Appl.*, vol. 289, p. 128330, 2025.
[2] W. Hong *et al.*, "Automated measurement of mouse social behaviors using depth sensing, video tracking, and machine learning," *Proc. Natl. Acad. Sci. USA*, vol. 112, no. 38, pp. E5351–E5360, 2015.
[3] N. Ravi *et al.*, "SAM 2: Segment anything in images and videos," *arXiv preprint*, 2024.
[4] G. Jocher *et al.*, "Ultralytics YOLO11," 2024.
[5] N. V. Chawla *et al.*, "SMOTE: Synthetic minority over-sampling technique," *J. Artif. Intell. Res.*, vol. 16, pp. 321–357, 2002.
[6] C. Segalin *et al.*, "The mouse action recognition system (MARS) software pipeline for automated analysis of social behaviors in mice," *J. eLife*, vol. 10, p. e63720, 2021.
[7] X. P. Burgos-Artizzu *et al.*, "Social behavior recognition in continuous video," in *Proc. IEEE CVPR*, pp. 1322–1329, 2012.